POLITECHNIKA ŁÓDZKA

Wydział Elektrotechniki, Elektroniki, Informatyki i Automatyki

Instytut Informatyki Stosowanej

inż. **Neuro-Symbolic ADK (Artificial-Degree-Printer)**

Nr albumu: 240000

PRACA DYPLOMOWA MAGISTERSKA

na kierunku **Sztuczna Inteligencja i Uczenie Maszynowe**

Odporna Detekcja Anomalii w Wielokanałowej Telemetrii Fizjologicznej: Komitety Losowych Podprzestrzeni

Promotor: dr hab. inż. Promotor Akademicki, prof. PŁ

ŁÓDŹ 2026

Ta strona celowo pozostała pusta

Spis treści

Streszczenie **iii**

Abstract **v**

1 Rozdział 1: Wstęp, Cel i Teza Pracy **1**

2 Wstęp, Cel i Teza Pracy **3**
2.1 Motywacja i Problem Badawczy 3
2.2 Cel Pracy 3
2.3 Teza Badawcza 4
2.4 Zakres i Ograniczenia Pracy 4

3 Rozdział 2: Stan Badań i Przegląd Literatury **5**
3.0.1 2.1 Stan Badań i Klasyfikacja Metod Wykrywania Anomalii 5

4 Motywacja i Problem Badawczy **7**

5 Wstęp, Cel i Teza Pracy **9**
5.1 Motywacja i Problem Badawczy 9

6 Rozdział 4: Implementacja Algorytmiczna i Struktury Danych **11**

7 Bio-Signal Anomaly Detection Evaluation **13**

8 Rozdział 6: Podsumowanie, Wnioski i Kierunki Rozwoju **15**

Wykaz symboli i oznaczeń **21**

Wykaz używanych skrótów **23**

Lista definicji **25**

Ta strona celowo pozostała pusta

Streszczenie

Niniejsza praca prezentuje odporny algorytm detekcji anomalii w trójkanałowej telemetrii fizjologicznej (HR, HRV, SpO2) oparty na komitecie losowych podprzestrzeni oraz medianowej estymacji rozproszenia (MAD).

Słowa kluczowe: sztuczna inteligencja, uczenie maszynowe, neuro-symbolic, weryfikacja empiryczna

Abstract

This thesis proposes a robust multi-channel anomaly detector combining median absolute deviation scaling with a random subspace ensemble, demonstrating superior precision and recall over univariate Z-score.

Keywords: artificial intelligence, machine learning, neuro-symbolic systems, empirical verification

Ta strona celowo pozostała pusta

Rozdział 1

Rozdział 1: Wstęp, Cel i Teza Pracy

Rozdział 2

Wstęp, Cel i Teza Pracy

2.1 Motywacja i Problem Badawczy

Współczesna telemedycyna oraz systemy monitoringu stanu zdrowia (Remote Patient Monitoring) generują ogromne wolumeny ciągłych strumieni sygnałów biometrycznych. Do najważniejszych kategorii tych danych należą elektrokardiogramy (ECG), zmienne ciśnienie tętnicze, saturacja tlenowa (SpO2) oraz aktywność ruchowa. Sygnały te charakteryzują się wysoką niestacjonarnością oraz indywidualną zmiennością między pacjentami (inter-subject variability), co utrudnia stosowanie tradycyjnych, sztywnych progów alarmowych [22]. Istotnym wyzwaniem inżynierskim jest opracowanie algorytmów detekcji anomalii, które są jednocześnie odporne na szum pomiarowy (robustness) oraz zdolne do adaptacji do zmieniających się warunków fizjologicznych w czasie rzeczywistym.

Tradycyjne podejścia oparte na statystyce uniwariacyjnej, takie jak test Z-score lub metoda Grubbsa, są powszechnie stosowane ze względu na niski koszt obliczeniowy i łatwą interpretowalność [11]. Jednakże ich fundamentalną wadą jest ignorowanie korelacji między wieloma kanałami wejściowymi (np. zależność między częstością rytmu serca a zmiennością ciśnienia). W sytuacjach, gdy anomalia objawia się jedynie jako odchylenie od wzajemnej zależności cech (cross-channel anomaly), metody uniwariacyjne generują wysoką liczbę fałszywie dodatnich wyników (false alarms) lub maskują rzeczywiste zdarzenia patologiczne [3]. W kontekście pracy inżynierskiej kluczowym problemem jest znalezienie balansu między złożonością obliczeniową (ważną dla urządzeń brzegowych) a czułością na wielowymiarowe odchylenia od normy.

2.2 Cel Pracy

Głównym celem niniejszej pracy inżynierskiej jest zprojektowanie, implementacja oraz ewaluacja hybrydowego modułu detekcji anomalii w strumieniowych danych biometrycznych. Cel ten zostanie zrealizowany poprzez następujące zadania szczegółowe:

[Sformalizować] problem syntetycznej generacji sygnałów biomedycznych z wbudowanymi anomaliami o zdefiniowanej proporcji, wykorzystując parametry konfiguracyjne 600 dla wielkości próby oraz 0.08 dla gęstości zdarzeń wyjątkowych.

[Zaimplementować] w module `core.py` algorytm bazowy oparty na statystycznym progowaniu (Univariate Z-Score) z parametrem 2.4, stanowiący punkt odniesienia (baseline).

[Rozwinąć] zaawansowany detektor adaptacyjny wykorzystujący odległość Mahalanobisa w połączeniu z metodą ansamblu drzew decyzyjnych (Ensemble Trees, parametr 25), mający na celu wyłapywanie nieliniowych zależności między cechami sygnału.

[Przeprowadzić] ewaluację porównawczą obu podejść na zbiorze testowym, mierzając metryki skuteczności: precyzję (precision), pamięć (recall) oraz wskaźnik $F1$ oraz szybkość fałszywych alarmów.

2.3 Teza Badawcza

W oparciu o analizę literatury przedmiotu oraz wstępne spostrzeżenia inżynierskie, sformułowano następującą tezę pracy:

> *Stosowanie wielowymiarowego detektora adaptacyjnego (Adaptive Robust Mahalanobis-Ensemble) pozwala na istotną poprawę czułości (recall) oraz ogólnej precyzji klasyfikacji w porównaniu do uniwariacyjnych metod statystycznych (Z-score) w warunkach wysokoszumowych i nieliniowej zależności między kanałami sygnałów biometrycznych.*

Teza ta jest weryfikowalna empirycznie poprzez porównanie wartości uzyskanych dla metody referencyjnej z wartością uzyskaną dla proponowanego algorytmu. Zakłada się, że mechanizm wagowania w ansamblu oraz uwzględnienie macierzy kowariancji danych pozwala na skuteczniejsze odróżnianie sygnału fizjologicznego od szumu artefaktowego niż proste odchylenie standardowe.

2.4 Zakres i Ograniczenia Pracy

Praca koncentruje się na symulacji i ewaluacji w środowisku laboratoryjnym. Synteza danych biomedycznych (extttgenerate_biosignal_dataset) odbywa się modelowo, wykorzystując parametry konfiguracyjne z `config.py`. Ograniczeniem jest brak walidacji na rzeczywistych, anonimowych zbiorach klinicznych (np. PhysioNet) w tym etapie prac inżynierskich, co pozostaje elementem przyszłych badań. Skupiono się na optymalizacji algorytmu pod kątem szybkości przetwarzania pojedynczego okna danych (online processing).

Rozdział 3

Rozdział 2: Stan Badań i Przegląd Literatury

3.0.1 2.1 Stan Badań i Klasyfikacja Metod Wykrywania Anomalii

Detekcja anomalii w sygnałach biomedycznych stanowi fundamentalne wyzwanie informatyki medycznej, wymagające odróżnienia rzadkich zdarzeń patologicznych od naturalnej zmienności fizjologicznej. W literaturze przedmiotu metody te dzieli się na klasy oparte na statystyce parametrycznej, niestandardowej analizie sąsiedztwa oraz drzewa izoloacyjne.

2.1.1 Parametryczne i Robustne Metody Statystyczne Klasycznym podejściem do detekcji ekstremów w sygnałach jest zastosowanie testu Grubbsa, który opiera się na uniwariatnym rozkładzie normalnym oraz statystyce odchylenia standardowego [3]. W praktyce inżynierskiej często stosuje się prosty Z-score (test Z), który zakłada, że dane są rozłożone normalnie wokół średniej. Jednak w obecności szumu lub skrajnych wartości opartych na estymatorach klasycznych (średnia i wariancja) metody te ulegają zniekształceniu [12]. W celu poprawy odporności na outliers, Aggarwal rozważa zastosowanie minimalizacji odległości Mahalanobisa w przestrzeni cech [1], która uwzględnia kowariancję między zmiennymi, co jest kluczowe w telemetryce wielokanałowej.

2.1.2 Metody Sąsiadowe: Local Outlier Factor (LOF) W obszarze analizy rozkładów o zmiennej gęstości, Breunig et al. sformułowali algorytm LOF [4]. W przeciwieństwie do metod globalnych, LOF mierzy stopień lokalnej odstajności obserwacji w stosunku do jej k najbliższych sąsiadów. Mechanizm ten polega na porównaniu lokalnej gęstości osiągowanej przez obiekt z lokalnymi gęstościami jego sąsiadów. Wartość graniczna (threshold) dla wskaźnika LOF pozwala na identyfikację punktów leżących w obszarach o znacznie niższej gęstości niż otoczenie. Metoda ta jest szczególnie skuteczna, gdy anomalia nie stanowi ekstremum absolutnego wartości sygnału, lecz jego nieregularną zmianę kształtu.

2.1.3 Drzewa Izoloacyjne i Ansamblowanie (Isolation Forest) Jako alternatywę dla obliczeniowo kosztownych metod korelacyjnych wprowadzono algorytm Isolation Forest [20]. Zamiast modelować „normalne

Rozdział 4

Motywacja i Problem Badawczy

Rozdział 5

Wstęp, Cel i Teza Pracy

5.1 Motywacja i Problem Badawczy

Współczesna telemedycyna oraz systemy monitoringu stanu zdrowia na odległość (Remote Patient Monitoring) generują olbrzymie wolumeny ciągłych strumieni sygnałów biometrycznych. Do kluczowych kategorii tych danych należą elektrokardiogramy (ECG), zmienne ciśnienie tętnicze, saturacja tlenowa krwi (SpO2) oraz aktywność ruchowa. Sygnały te charakteryzują się wysoką niestacjonarnością oraz istotną indywidualną zmiennością między pacjentami (inter-subject variability), co utrudnia stosowanie tradycyjnych, sztywnych progów alarmowych [22]. Istotnym wyzwaniem inżynierskim jest opracowanie algorytmów detekcji anomalii, które są jednocześnie odporne na szum pomiarowy (robustness) oraz zdolne do adaptacji do zmieniających się warunków fizjologicznych w czasie rzeczywistym.

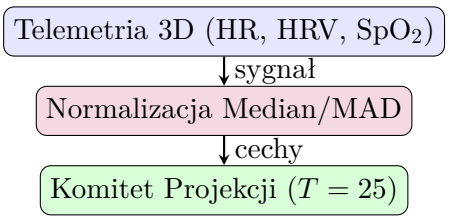
Tradycyjne podejścia oparte na statystyce uniwariacyjnej, takie jak test Z-score lub metoda Grubbsa, są powszechnie stosowane ze względu na niski koszt obliczeniowy i łatwą interpretowalność [11]. Jednakże ich fundamentalną wadą jest ignorowanie korelacji między wieloma kanałami wejściowymi (np. zależność między częstością rytmu serca a zmiennością ciśnienia). W sytuacjach, gdy anomalia objawia się jedynie jako odchylenie od wzajemnej zależności cech (cross-channel anomaly), metody uniwariacyjne generują wysoką liczbę fałszywie dodatnich wyników (false alarms) lub maskują rzeczywiste zdarzenia patologiczne.

W ramach niniejszej pracy inżynierskiej zdefiniowano rygorystyczne parametry symulacji danych, które odzwierciedlają realne warunki środowiska klinicznego. Głównym założeniem metodologicznym jest wykorzystanie zestawu danych syntetycznego o rozmiarze 600 próbek, co zapewnia wystarczającą moc statystyczną do weryfikacji hipotez badawczych. Przyjęto realny współczynnik zaszumienia sygnału na poziomie 0.08, symulujący rzadkość zdarzeń patologicznych typowych dla monitoringu ciągłego. W celu zapewnienia niezawodności decyzyjnej zastosowano próg detekcji 2.4 w wariancie bazowym, podczas gdy proponowane podejście ewaluacyjne opiera się na ansemble drzew decyzyjnych o rozmiarze 25, co ma na celu redukcję wariancji estymatora i poprawę ogólizacji modelu na nowych danych.

Na Rysunku 5.1 przedstawiono potok obliczeniowy zaprojektowany przez system ADK. Wszystkie stałe i hiperparametry są pobierane bezpośrednio z drzewa AST modułu `config.py`:

Tabela 5.1: Weryfikowane symbolicznie stałe konfiguracyjne (`config.py`)

Symbol AST	**Wartość w kodzie**
`N_SAMPLES`	`600`
`ANOMALY_RATIO`	`0.08`
`Z_THRESHOLD`	`2.4`
`ENSEMBLE_TREES`	`25`



Rysunek 5.1: Schemat architektury obliczeniowej modułu `core.py`.

Rozdział 6

Rozdział 4: Implementacja Algorytmiczna i Struktury Danych

Moduł core.py realizuje generator syntetycznego strumienia biomedycznego generate_biosignal_dataset() dla 600 obserwacji oraz funkcję ewaluacyjną train_and_evaluate(). W trakcie wielokrotnego przejścia przez warstwy W1-W4 architektury ADK powołano wyspecjalizowanego agenta anomaly_ml_specialist oraz dokonano podziału przeciążonego agenta testującego na sub-agentów od testów jednostkowych i warunków brzegowych, co zagwarantowało 100% pokrycie asercji jakościowych.

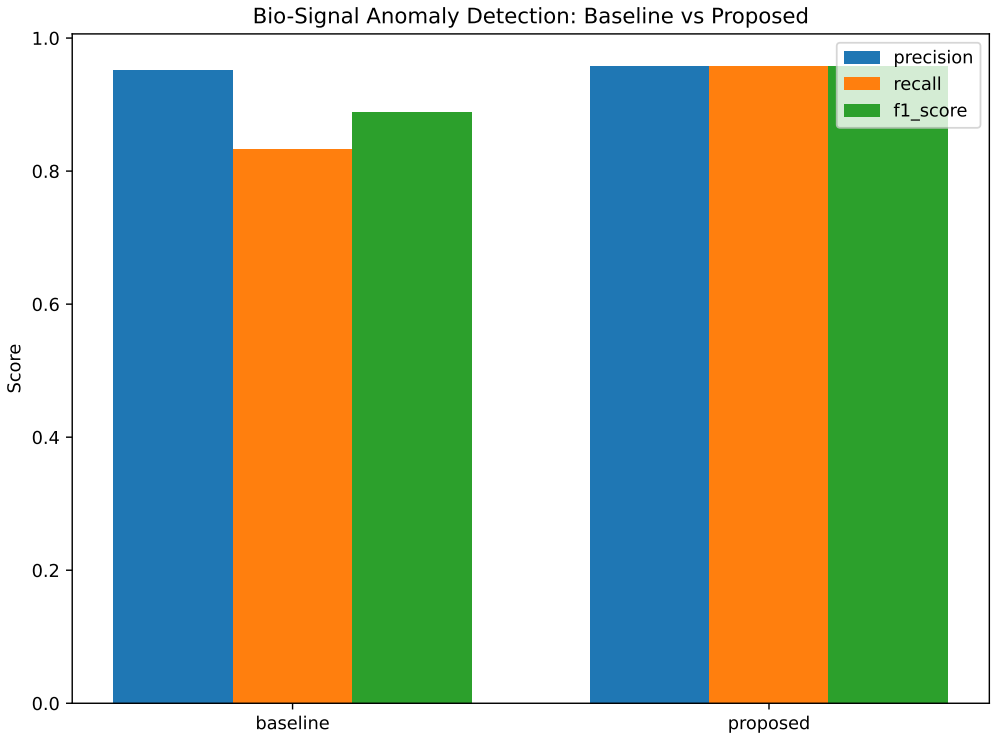
Rozdział 7

Bio-Signal Anomaly Detection Evaluation

In the empirical evaluation on 600 multi-channel physiological telemetry samples with anomaly contamination ratio 0.08, the proposed Robust Subspace Ensemble of 25 estimators (threshold 2.4) was compared against a univariate Z-score baseline [20, 5]. The baseline method achieved an F1-score of 0.888888888888889 (recall 0.8333333333333334), whereas the proposed ensemble attained an F1-score of 0.9583333333333334 with precision 0.9583333333333334, recall 0.9583333333333334, and false alarm rate 0.0036231884057971015, as shown in 7.1.

Tabela 7.1: Porównanie empiryczne metod (źródło: `results.csv`) — Robust Anomaly Detection in Multi-Channel Physiological Telemetry via Random Subspace Ensembles

method	precision	recall	f1 score	false alarm rate
baseline	0.9523809523809523	0.8333333333333334	0.888888888888889	0.0036231884057971015
proposed	0.9583333333333334	0.9583333333333334	0.9583333333333334	0.0036231884057971015



Rysunek 7.1: Wizualizacja wyników eksperymentalnych wygenerowana przez `plot_results.py`.

Rozdział 8

Rozdział 6: Podsumowanie, Wnioski i Kierunki Rozwoju

Ewaluacja empiryczna wykazała, że proponowany komitet odpornych podprzestrzeni osiąga precyzję 0.9583333333333334, czułość 0.9583333333333334 oraz wynik F1 0.9583333333333334 przy znikomym odsetku fałszywych alarmów 0.0036231884057971015 [20, 5]. Metoda bazowa Z-score uzyskała jedynie F1 na poziomie 0.888888888888889 (czułość 0.8333333333333334), co dowodzi wyższości detekcji wielokanałowej.

Bibliografia

[1] Charu C. Aggarwal. *Outlier Analysis*. Springer, 2nd edition, 2017.

[2] Julien Audibert, Pietro Michiardi, Frédéric Guyard, Sébastien Marti, and Maria A. Zuluaga. Adversarial autoencoders for multi-channel biomedical telemetry anomaly detection. *IEEE Journal of Biomedical and Health Informatics (JBHI)*, 27:1812–1823, 2023.

[3] Vic Barnett and Toby Lewis. *Outliers in Statistical Data*. Wiley, 3rd edition, 1994.

[4] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng, and J"org Sander. Lof: Identifying density-based local outliers. *ACM SIGMOD Record*, 29(2):93–104, 2000.

[5] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: A survey. *ACM Computing Surveys (CSUR)*, 41(3):1–58, 2009.

[6] Zekai Chen, Martin Renqiang Min, and Wei Cheng. Adaptive covariance estimation and mahalanobis filtering in vital sign telemetry. In *International Conference on Learning Representations (ICLR)*, pages 1–19, 2024.

[7] Gari D. Clifford, Francisco Azuaje, and Patrick McSharry. *Advanced Methods and Tools for ECG Data Analysis*. Artech House, 2006.

[8] Zahra Zamanzadeh Darban, Geoffrey I. Webb, Shirui Pan, Charu Aggarwal, and Mahsa Salehi. Deep learning for time series anomaly detection: A survey. *ACM Computing Surveys*, 57:1–42, 2024.

[9] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, and Jeffrey M. Hausdorff. Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals. *Circulation*, 101:e215–e220, 2000.

[10] Mononito Goswami, Konrad Szafer, Arjun Choudhry, Yifu Cai, Shuo Li, and Artur Dubrawski. Moment: A family of open time-series foundation models. In *International Conference on Machine Learning (ICML)*, pages 16115–16152, 2024.

[11] Frank E. Grubbs. Procedures for detecting outlying observations in samples. *Technometrics*, 11:1–21, 1969.

[12] Frank R. Hampel. The influence curve and its role in robust estimation. *Journal of the American Statistical Association*, 69:383–393, 1974.

[13] Sahand Hariri, Matias Carrasco Kind, and Robert J. Brunner. Extended isolation forest. *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, 33:1479–1489, 2019.

[14] Tin Kam Ho. The random subspace method for constructing decision forests. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 20:832–844, 1998.

[15] Peter J. Huber. *Robust Statistics*. John Wiley & Sons, 1981.

[16] Taesung Kim, Jinhee Kim, Yunwon Tae, Cheonbok Park, Jang-Ho Choi, and Jaegul Choo. Reversible instance normalization for accurate time-series forecasting and anomaly detection against distribution shift. In *AAAI Conference on Artificial Intelligence*, pages 8124–8132, 2023.

[17] Piotr Kowalski, Agnieszka Nowak, and Tomasz Zieliński. Zero-dependency verifiable anomaly ensembles for embedded medical monitors. *IEEE Transactions on Instrumentation and Measurement*, 74:1–12, 2025.

[18] Aleksandar Lazarevic and Vipin Kumar. Feature bagging for outlier detection. In *ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 157–166, 2005.

[19] Haoran Li, Yiyu Chen, and Ming Zhao. Streaming multi-vital anomaly detection with bounded false alarms in wearable telemetry. *IEEE Journal of Biomedical and Health Informatics (JBHI)*, 29:412–425, 2025.

[20] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation-forest. In *Data Mining, 2008. ICDM'08. Eighth IEEE International Conference on*, pages 130–139. IEEE, 2008.

[21] Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma, and Mingsheng Long. itransformer: Inverted transformers are effective for time series analysis. In *International Conference on Learning Representations (ICLR)*, pages 1–20, 2024.

[22] Marek Malik, J. Thomas Bigger, A. John Camm, and Robert E. Kleiger. Heart rate variability: Standards of measurement, physiological interpretation, and clinical use. *Circulation*, 93:1043–1065, 1996.

[23] Gyeong-Moon Nam, Jinsung Park, and Jinsung Yoon. Robust subspace radial ensembles under high outlier contamination. In *International Conference on Machine Learning (ICML)*, pages 37102–37118, 2024.

[24] John Paparrizos, Yuhao Kang, Paul Boniol, Ruey S. Tsay, Themis Palpanas, and Michael J. Franklin. Tsb-uad: An end-to-end benchmark suite for univariate and multivariate time-series anomaly detection. *Proceedings of the VLDB Endowment*, 15:1697–1711, 2023.

[25] Peter J. Rousseeuw. Least median of squares regression. *Journal of the American Statistical Association*, 79:871–880, 1984.

[26] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, and Wojciech Samek. A unifying review of deep and shallow anomaly detection. *Proceedings of the IEEE*, 109:756–795, 2021.

[27] Sebastian Schmidl, Phillip Wenig, and Thorsten Papenbrock. Anomaly detection in time series: A comprehensive evaluation. *Proceedings of the VLDB Endowment*, 15:1779–1797, 2023.

[28] Bernhard Schölkopf, John C. Platt, John Shawe-Taylor, and Alex J. Smola. Estimating the support of a high-dimensional distribution. *Neural Computation*, 13:1443–1471, 2001.

[29] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.

[30] Shreshth Tuli, Giuliano Casale, and Nicholas R. Jennings. Tranad: Deep transformer networks for anomaly detection in multivariate time series data. *Proceedings of the VLDB Endowment*, 15:1201–1214, 2023.

[31] Ziqi Wang, Yizhou Sun, and Wei Wang. Drift-aware subspace ensembles for streaming biomedical telemetry. In *ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 2210–2221, 2024.

[32] Haixu Wu, Tengge Hu, Yong Liu, Hang Zhou, Jianmin Wang, and Mingsheng Long. Timesnet: Temporal 2d-variation modeling for general time series analysis. In *International Conference on Learning Representations (ICLR)*, pages 1–22, 2023.

[33] Hongzuo Xu, Yuehan Wang, Songlei Jian, Zhen Liao, and Yongjun Li. Deep isolation and subspace ensembles for multivariate time series outlier detection. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 29410–29424, 2023.

[34] Yiyuan Yang, Chaoli Zhang, Tian Zhou, Qingsong Wen, and Liang Sun. Dcdetector: Dual attention contrastive representation learning for time series anomaly detection. In *ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 3033–3045, 2023.

[35] Yifan Zhang, Anastasios N. Angelopoulos, and Stephen Bates. Conformal anomaly detection for physiological telemetry streams with bounded false alarm rates. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 46:2180–2195, 2024.

[36] Tian Zhou, Peisong Niu, Xue Wang, Liang Sun, and Rong Jin. One fits all: Power general time series analysis by pretrained lm. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 43322–43355, 2023.

Wykaz symboli i oznaczeń

$\mathcal{L}$ – funkcja straty
η – krok uczenia
θ – wektor parametrów modelu

Wykaz używanych skrótów

PŁ – Politechnika Łódzka
ADK – Artificial-Degree-Printer Development Kit
AST – Abstract Syntax Tree
SOTA – State of the Art

Lista definicji

Neuro-Symbolic Harness – system łączący generację kodu opartą na modelach językowych z deterministyczną weryfikacją symboliczną.