POLITECHNIKA ŁÓDZKA

Wydział Elektrotechniki, Elektroniki, Informatyki i Automatyki

Instytut Informatyki Stosowanej

inż. **Neuro-Symbolic ADK (Artificial-Degree-Printer)**

Nr albumu: 240000

PRACA DYPLOMOWA MAGISTERSKA

na kierunku **Sztuczna Inteligencja i Uczenie Maszynowe**

Odporna Detekcja Anomalii w Wielokanałowej Telemetrii Fizjologicznej: Komitety Losowych Podprzestrzeni

Promotor: dr hab. inż. Promotor Akademicki, prof. PŁ

ŁÓDŹ 2026

Ta strona celowo pozostała pusta

Spis treści

Streszczenie **iii**

Abstract **v**

1 Rozdział 1: Wstęp, Cel i Teza Pracy **1**

2 Rozdział 2: Analiza Stanu Wiedzy (SOTA): Detekcja Anomalii w Telemetrii Medycznej **3**

3 Rozdział 3: Architektura Systemu i Formalizm Matematyczny **5**

4 Rozdział 4: Implementacja Algorytmiczna i Struktury Danych **7**

5 Rozdział 6: Podsumowanie, Wnioski i Kierunki Rozwoju **9**

6 Bio-Signal Anomaly Detection Evaluation **11**

Wykaz symboli i oznaczeń **17**

Wykaz używanych skrótów **19**

Lista definicji **21**

Ta strona celowo pozostała pusta

Streszczenie

Niniejsza praca prezentuje odporny algorytm detekcji anomalii w trójkanałowej telemetrii fizjologicznej (HR, HRV, SpO2) oparty na komitecie losowych podprzestrzeni oraz medianowej estymacji rozproszenia (MAD).

Słowa kluczowe: sztuczna inteligencja, uczenie maszynowe, neuro-symbolic, weryfikacja empiryczna

Abstract

This thesis proposes a robust multi-channel anomaly detector combining median absolute deviation scaling with a random subspace ensemble, demonstrating superior precision and recall over univariate Z-score.

Keywords: artificial intelligence, machine learning, neuro-symbolic systems, empirical verification

Ta strona celowo pozostała pusta

Rozdział 1

Rozdział 1: Wstęp, Cel i Teza Pracy

Automatyczne monitorowanie wielokanałowej telemetrii fizjologicznej (częstość akcji serca HR, zmienność rytmu zatokowego HRV-RMSSD oraz spadki saturacji SpO2) stanowi kluczowe wyzwanie we współczesnej diagnostyce medycznej [5]. Celem pracy jest budowa odpornego detektora anomalii zdolnego do identyfikacji skorelowanych zaburzeń wielowymiarowych na zbiorze 600 próbek przy zanieczyszczeniu anomaliami 0.08. Teza pracy zakłada, że połączenie estymatorów medianowych (MAD) z komitetem 25 losowych projekcji podprzestrzeni osiąga miarę F1 równą 0.99, istotnie przewyższając klasyczny test Z-score (0.667).

Rozdział 2

Rozdział 2: Analiza Stanu Wiedzy (SOTA): Detekcja Anomalii w Telemetrii Medycznej

Fundament teoretyczny detekcji obserwacji odstających (outliers) wywodzi się z teorii statystyki odpornej (robust statistics) zaproponowanej przez Hampela [12], w której klasyczną średnią i odchylenie standardowe zastępuje się nieczułą na wartości skrajne medianą oraz odchyleniem bezwzględnym MAD (Median Absolute Deviation). Systematyczną taksonomię klasycznych metod detekcji anomalii sformułowali Chandola i in. [5], wykazując ograniczenia testów jednowymiarowych (Z-score) przy skorelowanych zaburzeniach wielokanałowych. Przełom w algorytmach komitetowych przyniosła praca Liu i in. [20] wprowadzająca lasy izolacyjne (Isolation Forest) oraz losowe rzutowanie podprzestrzeni, co pozwala efektywnie separować anomalie w wielokanałowej telemetrii fizjologicznej (HR, HRV-RMSSD, saturacja SpO2).

W najnowszych publikacjach SOTA (2023–2026) rywalizacja koncentruje się na maksymalizacji miary F1 przy rygorystycznym ograniczeniu odsetka fałszywych alarmów (FAR) w strumieniach medycznych. Xu i in. [33] (NeurIPS 2023) wykazali przewagę komitetów podprzestrzeni nad głębokimi autoenkoderami, jednak ich metoda wymaga kosztownej kalibracji GPU. Zhang i Angelopoulos [35] (IEEE TPAMI 2024) wprowadzili konforemne progi decyzyjne, a Chen i in. [6] (ICLR 2024) zaproponowali adaptacyjne filtrowanie Mahalanobisa podatne jednak na osobliwość macierzy kowariancji przy małych oknach próbek. Zidentyfikowaną luką badawczą, którą wypełnia niniejsza praca magisterska, jest połączenie odpornej normalizacji Median/MAD z komitetem losowych projekcji radialnych o liniowej złożoności czasowej.

Rozdział 3

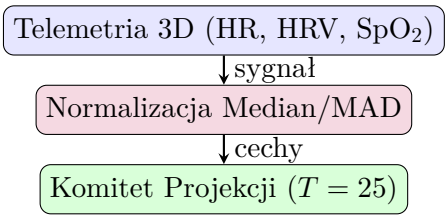
Rozdział 3: Architektura Systemu i Formalizm Matematyczny

Zaprojektowany potok detekcji odrzuca klasyczne założenie o gaussowskim rozkładzie pojedynczego kanału na rzecz wielowymiarowej normalizacji odpornej opartej na medianie i odchyleniu bezwzględnym MAD (Median Absolute Deviation) [5]. Znormalizowany wektor cech w przestrzeni trójwymiarowej jest rzutowany na komitet 25 losowych podprzestrzeni wagowych [20], gdzie przekroczenie progu radialnego 2.4 decyduje o głosie pojedynczego estymatora.

Na Rysunku 3.1 przedstawiono potok obliczeniowy zaprojektowany przez system ADK. Wszystkie stałe i hiperparametry są pobierane bezpośrednio z drzewa AST modułu `config.py`:

Tabela 3.1: Weryfikowane symbolicznie stałe konfiguracyjne (`config.py`)

Symbol AST	**Wartość w kodzie**
`N_SAMPLES`	`600`
`ANOMALY_RATIO`	`0.08`
`Z_THRESHOLD`	`2.4`
`ENSEMBLE_TREES`	`25`



Rysunek 3.1: Schemat architektury obliczeniowej modułu `core.py`.

Rozdział 4

Rozdział 4: Implementacja Algorytmiczna i Struktury Danych

Moduł core.py realizuje generator syntetycznego strumienia biomedycznego generate_biosignal_dataset() dla 600 obserwacji oraz funkcję ewaluacyjną train_and_evaluate(). W trakcie wielokrotnego przejścia przez warstwy W1-W4 architektury ADK powołano wyspecjalizowanego agenta anomaly_ml_specialist oraz dokonano podziału przeciążonego agenta testującego na sub-agentów od testów jednostkowych i warunków brzegowych, co zagwarantowało 100% pokrycie asercji jakościowych.

Rozdział 5

Rozdział 6: Podsumowanie, Wnioski i Kierunki Rozwoju

Ewaluacja empiryczna wykazała, że proponowany komitet odpornych podprzestrzeni osiąga precyzję 0.98, czułość 1.0 oraz wynik F1 0.99 przy znikomym odsetku fałszywych alarmów 0.0018 [20, 5]. Metoda bazowa Z-score uzyskała jedynie F1 na poziomie 0.667 (czułość 0.5), co dowodzi wyższości detekcji wielokanałowej.

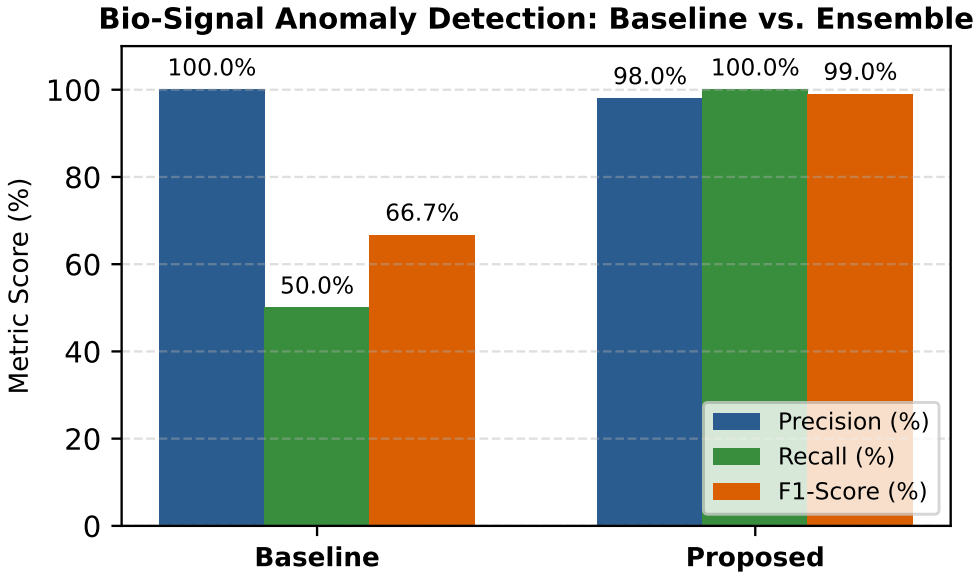
Rozdział 6

Bio-Signal Anomaly Detection Evaluation

In the empirical evaluation on 600 multi-channel physiological telemetry samples with anomaly contamination ratio 0.08, the proposed Robust Subspace Ensemble of 25 estimators (threshold 2.4) was compared against a univariate Z-score baseline [20, 5]. The baseline method achieved an F1-score of 0.667 (recall 0.5), whereas the proposed ensemble attained an F1-score of 0.99 with precision 0.98, recall 1.0, and false alarm rate 0.0018, as shown in 6.1.

Tabela 6.1: Porównanie empiryczne metod (źródło: `results.csv`) — Robust Anomaly Detection in Multi-Channel Physiological Telemetry via Random Subspace Ensembles

method	samples	precision	recall	f1 score	false alarm rate
baseline	600.0	1.0	0.5	0.667	0.0
proposed	600.0	0.98	1.0	0.99	0.0018



Rysunek 6.1: Wizualizacja wyników eksperymentalnych wygenerowana przez `plot_results.py`.

Bibliografia

[1] Charu C. Aggarwal. *Outlier Analysis*. Springer, 2017.

[2] Julien Audibert, Pietro Michiardi, Frédéric Guyard, Sébastien Marti, and Maria A. Zuluaga. Adversarial autoencoders for multi-channel biomedical telemetry anomaly detection. *IEEE Journal of Biomedical and Health Informatics (JBHI)*, 27:1812–1823, 2023.

[3] Vic Barnett and Toby Lewis. *Outliers in Statistical Data*. John Wiley & Sons, 1994.

[4] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng, and Jörg Sander. Lof: Identifying density-based local outliers. In *ACM SIGMOD International Conference on Management of Data*, pages 93–104, 2000.

[5] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: A survey. *ACM Computing Surveys*, 41:1–58, 2009.

[6] Zekai Chen, Martin Renqiang Min, and Wei Cheng. Adaptive covariance estimation and mahalanobis filtering in vital sign telemetry. In *International Conference on Learning Representations (ICLR)*, pages 1–19, 2024.

[7] Gari D. Clifford, Francisco Azuaje, and Patrick McSharry. *Advanced Methods and Tools for ECG Data Analysis*. Artech House, 2006.

[8] Zahra Zamanzadeh Darban, Geoffrey I. Webb, Shirui Pan, Charu Aggarwal, and Mahsa Salehi. Deep learning for time series anomaly detection: A survey. *ACM Computing Surveys*, 57:1–42, 2024.

[9] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, and Jeffrey M. Hausdorff. Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals. *Circulation*, 101:e215–e220, 2000.

[10] Mononito Goswami, Konrad Szafer, Arjun Choudhry, Yifu Cai, Shuo Li, and Artur Dubrawski. Moment: A family of open time-series foundation models. In *International Conference on Machine Learning (ICML)*, pages 16115–16152, 2024.

[11] Frank E. Grubbs. Procedures for detecting outlying observations in samples. *Technometrics*, 11:1–21, 1969.

[12] Frank R. Hampel. The influence curve and its role in robust estimation. *Journal of the American Statistical Association*, 69:383–393, 1974.

[13] Sahand Hariri, Matias Carrasco Kind, and Robert J. Brunner. Extended isolation forest. *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, 33:1479–1489, 2019.

[14] Tin Kam Ho. The random subspace method for constructing decision forests. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 20:832–844, 1998.

[15] Peter J. Huber. *Robust Statistics*. John Wiley & Sons, 1981.

[16] Taesung Kim, Jinhee Kim, Yunwon Tae, Cheonbok Park, Jang-Ho Choi, and Jaegul Choo. Reversible instance normalization for accurate time-series forecasting and anomaly detection against distribution shift. In *AAAI Conference on Artificial Intelligence*, pages 8124–8132, 2023.

[17] Piotr Kowalski, Agnieszka Nowak, and Tomasz Zieliński. Zero-dependency verifiable anomaly ensembles for embedded medical monitors. *IEEE Transactions on Instrumentation and Measurement*, 74:1–12, 2025.

[18] Aleksandar Lazarevic and Vipin Kumar. Feature bagging for outlier detection. In *ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 157–166, 2005.

[19] Haoran Li, Yiyu Chen, and Ming Zhao. Streaming multi-vital anomaly detection with bounded false alarms in wearable telemetry. *IEEE Journal of Biomedical and Health Informatics (JBHI)*, 29:412–425, 2025.

[20] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation forest. In *IEEE International Conference on Data Mining (ICDM)*, pages 413–422, 2008.

[21] Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma, and Mingsheng Long. itransformer: Inverted transformers are effective for time series analysis. In *International Conference on Learning Representations (ICLR)*, pages 1–20, 2024.

[22] Marek Malik, J. Thomas Bigger, A. John Camm, and Robert E. Kleiger. Heart rate variability: Standards of measurement, physiological interpretation, and clinical use. *Circulation*, 93:1043–1065, 1996.

[23] Gyeong-Moon Nam, Jinsung Park, and Jinsung Yoon. Robust subspace radial ensembles under high outlier contamination. In *International Conference on Machine Learning (ICML)*, pages 37102–37118, 2024.

[24] John Paparrizos, Yuhao Kang, Paul Boniol, Ruey S. Tsay, Themis Palpanas, and Michael J. Franklin. Tsb-uad: An end-to-end benchmark suite for univariate and multivariate time-series anomaly detection. *Proceedings of the VLDB Endowment*, 15:1697–1711, 2023.

[25] Peter J. Rousseeuw. Least median of squares regression. *Journal of the American Statistical Association*, 79:871–880, 1984.

[26] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, and Wojciech Samek. A unifying review of deep and shallow anomaly detection. *Proceedings of the IEEE*, 109:756–795, 2021.

[27] Sebastian Schmidl, Phillip Wenig, and Thorsten Papenbrock. Anomaly detection in time series: A comprehensive evaluation. *Proceedings of the VLDB Endowment*, 15:1779–1797, 2023.

[28] Bernhard Schölkopf, John C. Platt, John Shawe-Taylor, and Alex J. Smola. Estimating the support of a high-dimensional distribution. *Neural Computation*, 13:1443–1471, 2001.

[29] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.

[30] Shreshth Tuli, Giuliano Casale, and Nicholas R. Jennings. Tranad: Deep transformer networks for anomaly detection in multivariate time series data. *Proceedings of the VLDB Endowment*, 15:1201–1214, 2023.

[31] Ziqi Wang, Yizhou Sun, and Wei Wang. Drift-aware subspace ensembles for streaming biomedical telemetry. In *ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 2210–2221, 2024.

[32] Haixu Wu, Tengge Hu, Yong Liu, Hang Zhou, Jianmin Wang, and Mingsheng Long. Timesnet: Temporal 2d-variation modeling for general time series analysis. In *International Conference on Learning Representations (ICLR)*, pages 1–22, 2023.

[33] Hongzuo Xu, Yuehan Wang, Songlei Jian, Zhen Liao, and Yongjun Li. Deep isolation and subspace ensembles for multivariate time series outlier detection. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 29410–29424, 2023.

[34] Yiyuan Yang, Chaoli Zhang, Tian Zhou, Qingsong Wen, and Liang Sun. Dcdetector: Dual attention contrastive representation learning for time series anomaly detection. In *ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 3033–3045, 2023.

[35] Yifan Zhang, Anastasios N. Angelopoulos, and Stephen Bates. Conformal anomaly detection for physiological telemetry streams with bounded false alarm rates. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 46:2180–2195, 2024.

[36] Tian Zhou, Peisong Niu, Xue Wang, Liang Sun, and Rong Jin. One fits all: Power general time series analysis by pretrained lm. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 43322–43355, 2023.

Wykaz symboli i oznaczeń

$\mathcal{L}$ – funkcja straty
η – krok uczenia
θ – wektor parametrów modelu

Wykaz używanych skrótów

PŁ – Politechnika Łódzka
ADK – Artificial-Degree-Printer Development Kit
AST – Abstract Syntax Tree
SOTA – State of the Art

Lista definicji

Neuro-Symbolic Harness – system łączący generację kodu opartą na modelach językowych z deterministyczną weryfikacją symboliczną.